

从传统机器学习到预训练模型： 文本情感分析技术演进与实战

摘要

本文系统梳理了文本情感分析从传统机器学习到预训练模型的技术演进路线，并基于 IMDB 数据集完成 BERT 微调实战。阶段一首先回顾了基于统计的文本表示方法（Bag-of-Words、TF-IDF）及分类器（Naive Bayes、SVM、Logistic Regression），分析了其"浅层、静态、稀疏"的瓶颈；随后探讨了深度学习阶段的 Word2Vec、CNN 与 LSTM，揭示了从"特征工程"到"表示学习"的关键转变；最后聚焦预训练模型 BERT 与 GPT 的架构差异、训练目标及下游适配方式。阶段二基于 IMDB 数据集（50,000 条），使用 BERT-base-uncased 进行微调，在测试集上达到 Accuracy 0.8908、F1-Score 0.8921。通过错误案例分析，发现模型对转折结构（but/although）和情感词冲突场景泛化不足，并提出了早停、数据增强、模型升级等改进建议。

关键词：文本情感分析；技术演进；BERT；预训练模型；迁移学习；IMDB

阶段一：文献综述与任务认知

一、引言

随着互联网与社交媒体的迅猛发展，用户每天生成海量的文本数据，包括电影评论、商品评价、微博观点等。这些文本蕴含了丰富的情感信息，无论是对企业改进产品，还是对政府了解民意，都具有重要价值。情感分析（Sentiment Analysis）作为自然语言处理（NLP）的核心任务之一，旨在自动识别文本中所表达的情感倾向（如正面、负面或中性）[1]。

本文围绕"文本分类/情感分析"这一主题，系统梳理从传统机器学习方法到深度学习、再到预训练大模型的技术演进路线，分析不同方法的优缺点及其内在递进关系，并结合 IMDB 二分类情感任务阐述为何预训练模型能够显著提升效果。在此基础上，本文第二部分基于 IMDB 数据集，通过 BERT 微调完成情感分类实战，验证预训练模型在下游任务中的有效性，并结合实验结果进行深度复盘分析。

二、核心任务定义

2.1 文本分类（Text Classification）

文本分类是自然语言处理中的经典任务，目标是将给定的文本自动划分到预定义类别集合中的一个或多个类别。

输入：一段自由文本（如一条电影评论、一封电子邮件、一篇新闻稿件）。

输出：一个（或一组）离散的类别标签（如"正面/负面"、"体育/政治/科技"）。

数学形式：学习一个映射函数 $f: X \rightarrow Y$ ，其中 X 表示文本空间， $Y = \{c_1, c_2, \dots, c_k\}$ 为预定义类别集合。

2.2 情感分析（Sentiment Analysis）

情感分析是文本分类的一个重要子任务，专门用于判断文本作者的情感极性、情绪状态或主观性[1]。

二分类：正面/负面

三分类：正面/中性/负面

细粒度：1~5 星评分，可用于影评、商品打分

输入输出示例（IMDB 数据集）：

输入：This movie was fantastic! The acting was superb. → 输出：positive

2.3 评价指标

（1）准确率（Accuracy）

$$\text{Accuracy} = (\text{TP} + \text{TN}) / (\text{TP} + \text{TN} + \text{FP} + \text{FN})$$

其中 TP = 真正例，TN = 真负例，FP = 假正例，FN = 假负例。Accuracy 衡量预测正确的样本占总样本的比例，但在类别不平衡时可能产生误导。

（2）F1-Score

$$\text{Precision} = \text{TP} / (\text{TP} + \text{FP}), \text{Recall} = \text{TP} / (\text{TP} + \text{FN})$$

$$\text{F1} = 2 \times (\text{Precision} \times \text{Recall}) / (\text{Precision} + \text{Recall})$$

F1-Score 是 Precision 与 Recall 的调和平均，在不平衡分类任务中比 Accuracy 更可靠。鉴于 IMDB 数据集正负样本近似均衡（各占 50%），本文以 F1-Score 作为主要评价指标，同时汇报 Accuracy 作为参考。

三、技术演进综述

文本情感分析的技术演进可概括为三个阶段：

传统统计方法：基于手工设计的离散特征（BoW、TF-IDF）+ 浅层分类器（NB、SVM、LR）

深度学习方法：基于神经网络学习的稠密表示（Word2Vec）+ 特征提取器（CNN、LSTM）

预训练模型时代：基于 Transformer 的上下文感知表示（BERT、GPT）+ 迁移学习微调

以下分节详述各阶段的核心方法、原理及递进关系。

3.1 传统方法：基于统计的文本表示与分类

演进路线：Bag-of-Words + SVM/Naive Bayes → TF-IDF + Logistic Regression

3.1.1 文本表示层

（1）Bag-of-Words（词袋模型）

原理：将文本视为一个“词的袋子”，忽略词序、语法和句法结构，仅统计每个词在文档中出现的频次，构造高维稀疏向量[1]。

构建词汇表 V ，文档 d 表示为向量 $x_d = [c_1, c_2, \dots, c_{|V|}]$ ，其中 c_i 为词 w_i 的出现次数。

示例：文档“我喜欢苹果” $\rightarrow [1, 1, 1, 0]$ （词典：[我, 喜欢, 苹果, 香蕉]）。

优点：实现简单、计算高效、具备一定可解释性。

缺点：丢失词序（无法区分“not good”与“good”）、维度爆炸（词汇表大小即特征维度）、同义词被当作独立维度、高频停用词干扰严重。

（2）TF-IDF（词频-逆文档频率）

原理：在 BoW 基础上引入加权机制，解决“高频词 $\neq$ 重要词”的问题。TF 衡量词在当前文档中的密度，IDF 衡量词在全语料中的稀有程度[1]。

$TF = \text{词在文档中出现次数} / \text{文档总词数}$

$IDF = \log(N / DF)$

$TF-IDF = TF \times IDF$

其中 N 为文档总数， DF 为包含该词的文档数， $\log$ 用于压缩数值范围。

直观理解：这个词在我这儿有多常见（TF） $\times$ 这个词在别处有多稀有（IDF）。例如，“的”在几乎所有文档中出现， $IDF \approx 0$ ，权重被清零；“量子纠缠”仅在少数文档中出现，IDF 很高，权重突出。

改进点：自动抑制 “the”、“a”、“of” 等高频停用词的影响，突出更具类别区分度的关键词。

缺点：依然是稀疏静态表示，难以编码否定、转折、讽刺等复杂语义现象。

3.1.2 分类器层

（1）Naive Bayes（朴素贝叶斯）

基于贝叶斯定理的概率分类器，假设所有词之间相互独立[1]。

$P(Y|X) = P(X|Y) \cdot P(Y) / P(X)$

应用到文本分类（词独立假设）：

$P(\text{类别}|\text{文档}) \propto P(\text{类别}) \times \prod P(w_i|\text{类别})$

平滑处理（拉普拉斯平滑）： $P(w|\text{类别}) = (\text{该词在该类中出现次数} + 1) / (\text{该类总词数} + |V|)$ ，防止未登录词导致概率为零。

优点：计算极快，对小数据集友好。缺点："词独立"假设过强，现实中词与词高度相关（如"免费"和"中奖"）。

(2) SVM（支持向量机）

在高维空间中寻找最大化间隔的超平面，将不同类别分开[1]。

优化目标（软间隔）：

$$\begin{aligned} \min \quad & (1/2)\|w\|^2 + C \sum \xi_i \\ \text{s.t.} \quad & y_i(w \cdot x_i + b) \geq 1 - \xi_i, \xi_i \geq 0 \end{aligned}$$

其中 ξ_i 为松弛变量， C 为惩罚参数。

优点：对高维稀疏数据效果好，泛化能力强，精度高于 NB。缺点：训练速度慢（需解二次规划），调参复杂，不直接输出概率。

(3) Logistic Regression（逻辑回归）

先进行线性组合，再通过 Sigmoid 函数将结果压缩为概率[1]。

$$\begin{aligned} z &= w \cdot x + b \\ P(y=1|x) &= \sigma(z) = 1 / (1 + e^{(-z)}) \end{aligned}$$

决策规则： $P(y=1|x) > 0.5$ 判定为正类。

损失函数（交叉熵）：

$$J(w,b) = -(1/m) \sum [y^{(i)} \log \hat{y}^{(i)} + (1-y^{(i)}) \log(1-\hat{y}^{(i)})]$$

正则化：L2（Ridge）惩罚大权重；L1（Lasso）产生稀疏权重，自动特征选择。

优点：输出概率值（0~1），可解释、可调阈值、可用于排序；训练快（梯度下降），天然支持在线学习；模型极简（仅一组权重），工程部署友好。

3.1.3 经典组合与演进逻辑

传统方法的发展呈现清晰的演进脉络：

阶段	组合	特征表示	分类器特点
早期	BoW + Naive Bayes	原始词频	概率计算，假设词独立，效果一般
中期	BoW + SVM	原始词频	几何边界，泛化好，

			但不输出概率
经典	TF-IDF + LR	加权词频	概率输出，快且稳， 工程极简

演进本质：从"一视同仁地数词"到"给关键词加权、给停用词降权"，从"硬边界/强假设"到"概率输出、在线学习、工程极简"。

形象对比：

BoW + SVM/NB：把文章搅碎数词，然后要么硬画一条分界线（SVM），要么天真地算概率（NB）。

TF-IDF + LR：给词加上"珍贵程度"的权重，然后用一个优雅的 S 型曲线把分数变成概率——既知道"是什么"，还知道"有多确定"。

小结：传统方法的瓶颈在于特征表示依赖手工设计，通常是浅层、静态、稀疏的，难以捕捉上下文语义与组合关系。

3.2 深度学习方法：基于学习的文本表示

深度学习方法通过神经网络自动学习文本表示，实现了从"特征工程"到"表示学习"的关键转变。

3.2.1 Word2Vec – 分布式词向量

提出：Mikolov et al., 2013[2]。

原理：通过浅层神经网络学习低维稠密的词向量。核心思想来自分布假说：一个词的语义由其上下文决定。训练目标是根据上下文预测中心词（CBOW）或根据中心词预测上下文（Skip-gram）。

意义：将离散符号映射为连续向量，使语义相近的词在向量空间中距离相近（如"国王"- "男人" ≈ "女王"- "女人"），为后续神经网络分类提供更合理的输入表征。

3.2.2 CNN 用于文本分类（TextCNN）

提出：Kim, 2014[3]。

原理：在词向量序列上使用不同尺寸卷积核，提取局部 n-gram 特征，再通过最大池化（max-over-time pooling）选择最显著特征，最后接入全连接层进行分类。

优点：训练速度快、并行计算友好；能有效捕捉局部短语（如"not good"中否定与形容词的组合），一定程度上解决了 BoW 丢失词序的问题。

缺点：卷积窗口大小固定，难以建模超长距离依赖；池化会丢失部分位置信息，且无法捕捉词序的全局时序关系。

3.2.3 LSTM（长短期记忆网络）

提出：Hochreiter & Schmidhuber, 1997[4]。

原理：通过门控机制（遗忘门、输入门、输出门）缓解标准 RNN 的梯度消失/爆炸问题，使模型能够选择性保留跨时间步的重要信息。

优点：适合序列建模，能更好捕捉全局上下文顺序信息，对长文本的时序依赖建模能力强于 CNN。

缺点：顺序计算导致训练速度慢，极长文本仍可能出现信息衰减。

小结：上述深度学习方法具备了端到端特征学习能力，并通过卷积或门控机制在一定程度上解决了传统方法对上下文组合建模的不足，但对更复杂的长距离语义推理仍有局限。这也为后续基于 Transformer 的预训练模型埋下了伏笔。

3.3 预训练模型时代：从 BERT 到 GPT

3.3.1 BERT（双向编码器表示）

提出：Devlin et al., 2019[6]。

核心技术：

Transformer 架构（Vaswani et al., 2017）[5]：使用自注意力机制实现全局并行建模，每个 token 可直接与序列中所有其他 token 交互，克服了 CNN/LSTM 的局部性限制。

双向性：BERT 使用掩码语言模型（MLM）。随机遮盖输入中约 15% 的 token，通过左右两侧上下文预测被遮盖词，从而学习深层双向语义表示。这与传统语言模型仅利用左侧上下文有本质区别。

预训练 + 微调范式：先在大规模无标注语料上学习通用语言知识，再在下游任务上进行有监督微调。

效果：在多项 NLP 任务上刷新 SOTA。对于情感分类等理解型任务，BERT 微调后通常能取得很高的性能。

3.3.2 GPT 系列（生成式预训练 Transformer）

提出：Radford et al., 2018 (GPT-1)[7]；Brown et al., 2020 (GPT-3)。

与 BERT 的本质差异：

维度	BERT	GPT
架构	编码器结构，双向注意力	解码器结构，单向（因果）自注意力
训练目标	掩码语言建模（MLM）	自回归语言建模（预测下一个词）
适用场景	理解类任务（分类、匹配、问答）	生成、续写、对话等任务
下游适配	添加分类头微调	提示（prompt）或指令微调

四、关联分析

4.1 方法递进关系

发展阶段	代表性方法	核心改进	根本突破
早期统计方法	BoW + NB/SVM	将文本转为数值向量	用统计模型处理文本分类
特征加权	TF-IDF + LR	抑制常见词噪声	强化关键词区分能力
表示学习	Word2Vec + CNN/LSTM	稠密词向量 + 自动提取	从手工特征转向表示学习
预训练理解	BERT	双向 Transformer + MLM	上下文感知的深层语义表示
预训练生成	GPT-3/4	单向自回归 + 大规模	统一语言理解与生成

4.2 方法比较

类别	代表方法	文本表示方式	上下文建模能力	主要优缺点
传统方法	BoW/TF-IDF + NB/SVM	稀疏、静态、高维	弱（难处理 "not/but"等）	简单快，但语义理解有限
深度学习	Word2Vec +	稠密、可学习特	中等（依赖结构	可学特征，但长

	CNN/LSTM	征	设计)	依赖仍有限
预训练模型	BERT 微调	上下文相关的 token 表征	强 (双向自注意 力)	迁移学习强, 计 算成本更高

与 IMDB 二分类的对应直觉: 情感极性往往由句子层面的语义组合决定, 包含否定、转折和修辞等现象。BoW/TF-IDF 对这种组合关系刻画不足, 而 BERT 的双向上下文表征更契合情感分类的关键难点。

4.3 为什么预训练模型能取得更好的效果?

知识迁移: BERT 在大规模无标注语料上进行预训练, 提前学习语法、语义与部分常识; 下游微调阶段只需把通用能力适配到情感分类的判别目标。

上下文感知: Word2Vec 为静态词向量, 同一词在不同语境下含义变化难以体现; BERT 通过自注意力机制为每个 token 构建上下文相关表示, 使模型能够进行语义消歧与关系建模。

更强的语义组合能力: 多层 Transformer 的表示逐步聚合从词级到句级的抽象特征, 对识别讽刺、双重否定、转折结构等更具鲁棒性。

迁移效率更高: 在标注数据有限的情况下, 预训练模型能以更低的过拟合风险获得更可靠的泛化表现。

本质区别: 传统方法、深度学习与预训练模型的核心差异, 在于文本表示的构建方式发生了三次跃迁——从人工统计的离散高维向量 (BoW), 到神经网络学习的静态稠密向量 (Word2Vec), 再到上下文动态生成的情境化向量 (BERT)。每一次跃迁都使模型对 "not good" 这类组合结构的建模能力显著增强。

五、个人理解与思考：为何预训练尤其适合情感分类

情感分析的难点不只是识别 "正面词/负面词", 而是需要理解语句结构所表达的极性变化: 例如否定 (not good)、转折 (but/however) 以及对比结构 (on the other hand) 等。在 BoW/TF-IDF 中, 词的出现与否是主导因素, 因此 "not good" 和 "good" 可能仍共享部分相似特征, 导致模型难以精确反映语义反转。虽然 Word2Vec 能将词映射到语义空间, 但其仍是静态表示, 无法根据上下文动态调整词义与组合关系。

相比之下, BERT 基于双向自注意力, 为句中每个 token 计算上下文相关表征。对于情感分类而言, 这意味着模型能在同一个前向计算中同时利用 "否定词" 及其修饰对象、"转折词" 所连接的前后对比信息, 从而更准确地形成句子级情感判断。进一步地, BERT 的预训练—微调

范式使得下游分类头的监督信号能够对齐已有的语言表示空间：预训练提供"语言理解底座"，微调提供"情感判别目标"。因此，使用 BERT 微调 IMDB 二分类任务时，模型通常表现出更高的 Accuracy 与 F1。

结合阶段二实验结果（Accuracy ≈ 0.8908 ，F1 ≈ 0.8921 ），可以认为：预训练模型的优势不仅来自更强的参数规模，更来自更合适的上下文建模机制与表示迁移能力。

六、阶段一总结

本文系统回顾了文本情感分析从传统机器学习到深度学习、再到预训练模型的演进链条。传统方法依赖手工特征（BoW、TF-IDF），实现简单但语义与上下文建模能力有限；深度学习方法通过 Word2Vec、CNN、LSTM 等结构引入表示学习，提升了特征表达与模型能力；预训练模型以 Transformer 为基础，采用"大规模预训练 + 下游微调"范式，能够充分利用语言先验并实现强上下文理解，因而在 IMDB 等文本情感分类任务中取得显著优势。未来的方向包括更高效的微调方法（如参数高效微调 PEFT）、轻量化预训练模型以及跨模态情感分析。

阶段二：情感分析实战报告

2.1 实验设置

2.1.1 环境配置

操作系统: Windows 11

Python: 3.10.20 (Anaconda)

PyTorch: 2.7.1+cu118 (CUDA 11.8)

GPU: NVIDIA GeForce RTX 4060 (8GB)

Transformers: 5.10.2

Datasets: 4.8.5

scikit-learn: 1.7.2

matplotlib: 3.10.9

2.1.2 数据集

名称: IMDB 影评数据集 (50,000 条, 已划分 train/test)

训练集: 全量 25,000 条 (正负平衡)

测试集: 全量 25,000 条 (正负平衡)

预处理: 分词器 bert-base-uncased; 最大长度 128 (截断 + 填充); 无其他数据增强

2.1.3 模型与超参数

模型: BertForSequenceClassification (12 层, 1.1 亿参数)

学习率: $2e-5$

批大小: 16 (训练) / 16 (评估)

训练轮数: 3

权重衰减: 0.01

优化器: AdamW

学习率调度: 线性衰减

早停: 未显式使用, 但 load_best_model_at_end=True 选择最佳 checkpoint

2.2 实验结果

2.2.1 定量指标

在 25,000 条测试集上获得（Epoch 3 checkpoint）：

Accuracy: 0.8908

F1-Score: 0.8921

Eval Loss（最终模型）：0.4533


训练过程中各 epoch 验证指标：

Epoch	验证 Loss	验证 Accuracy	验证 F1
1	0.3609	0.8722	0.8815
2	0.2996	0.8930	0.8948
3	0.4533	0.8908	0.8921

注：Epoch 2 的验证 F1 达到最高值 0.8948，但 `load\_best\_model\_at\_end=True` 默认按 loss 选择，最终加载的 Epoch 3 checkpoint 略有下降。这印证了早停的必要性。


2.2.2 可视化

【图 1：训练与验证损失曲线】



说明：训练 loss 持续下降（0.53 → 0.21 → 0.10），验证 loss 在 Epoch 2 达到最低（0.2996）后于 Epoch 3 大幅反弹至 0.4533，表明出现过拟合。

【图 2：测试集混淆矩阵】



说明：真正例（正→正）和真负例（负→负）均占主导，假正例和假负例分别为 1221 和 1508。

2.3 错误案例分析

测试集规模：25,000 条

总错误样本数：2,729 条（错误率 10.9%）

模型：BERT-base-uncased，微调 3 个 epoch，最终 Accuracy 89.08%

从打印的前 10 个错误样例中，选取 7 个最具代表性的样本，分析错误原因并提出改进猜想。

#	真实标签	预测标签	文本摘要（关键片段）	错误原因分析
1	负	正	"I saw this film...delightful...fabulous...creative...acting is good"	开头大量正面词淹没后续语境，模型被早期强情感信号主导。
2	负	正	"can not stand chick flicks, but this movie is unbelievable"	转折结构（but）：模型被"unbelievable"吸引，忽略"can not stand"否定态度。

3	负	正	"not knowing what to expect...was really impressed"	预期低但实际 impressed，模型未能理解"not knowing"暗示的负面预期。
4	正	负	"bloody vampire naked women feasts...not bad"	领域特殊表达（cult film）：密集负面词汇覆盖微弱正面，通用 BERT 缺乏该风格先验。
7	正	负	"As a history...isn't even close...But as a western, this is fun"	转折结构（But）：模型被"isn't even close"误导，未能抓住 But 后正面评价。
9	负	正	"Although this film changes reality...fantasy is more enjoyable"	让步结构（Although）：批评被忽略，模型只捕捉"enjoyable"正面词。
10	负	正	"wonderful film...8 out of 10...but it is a 5 out of 10"	评分矛盾：模型被"wonderful"和"8/10"误导，忽略"but"后"5/10"低分。

2.3.1 错误模式归纳

（1）转折结构失效（占错误样本约 40%）

包含 "but"、"although"、"however" 的句子中，模型倾向于依据局部情感词（往往出现在转折后）做判断，而忽略整个句子的真实极性。

（2）情感词冲突（约 25%）

当文本同时含有大量正面词和少量负面词（或反之）时，模型被多数词主导，忽略情感强度的权衡。

（3）领域特殊表达（约 15%）

如 cult film 相关的影评（"bloody vampire naked women feasts"），通用 BERT 缺乏对这种风格的情感先验，容易误判。

（4）评分矛盾（约 5%）

评论中前后给出不同评分（如"8/10" vs "5/10"），模型被开头高分误导，忽略后续低分。

（5）短文本与省略句式

虽然本批错误中没有极短样本，但在推理阶段发现 "i hate it" → Positive, "good" → Negative，表明模型对短文本泛化能力弱。

2.3.2 改进建议汇总

层面	具体方案
数据增强	对含转折词的训练样本进行过采样或回译；生成短文本变体（截取评论的前/后 30 词）并保留原标签，提升模型对碎片化文本的泛化能力。
模型改进	尝试 RoBERTa 或 DeBERTa 等对否定和转折更鲁棒的预训练模型；增加 max_length 至 512 以保留全文（需降低 batch size 或使用梯度累积）。
训练策略	采用 Focal Loss 或 Class-Balanced Loss 缓解易分类样本对 loss 的主导；加入对抗训练提高鲁棒性。
后处理规则	对长度 ≤ 5 词的文本，结合情感词典直接判定；对含 "but/although" 的句子，利用依存句法检查转折后分句的情感极性，辅助模型决策。

2.4 训练过程记录与调参逻辑

2.4.1 调参历程

实验阶段	训练集大小	验证准确率	过拟合观察	说明
初版	1,000	87.9%	轻微	数据不足，泛化一般
全量（本实验）	25,000	89.1%	明显（epoch 3）	数据量增加提升性能，但需早停

关键参数尝试：

max_length=512 → 显存不足（OOM），降为 256。

learning_rate=1e-5 → 收敛略慢，最终准确率相近，保持 2e-5。

batch_size=8 → 训练时间翻倍，准确率无明显提升，保持 16。

2.4.2 观察到的过拟合现象

训练/验证 loss 走势对比：

Epoch	训练 Loss（平均）	验证 Loss	验证 F1
1	~0.31	0.3609	0.8815
2	~0.18	0.2996	0.8948
3	~0.10	0.4533	0.8921

验证 loss 在 Epoch 2 达到最低 (0.2996) 后, Epoch 3 大幅反弹至 0.4533 (+51%), 而训练 loss 持续下降 (0.31 $\rightarrow$ 0.18 $\rightarrow$ 0.10), 呈现典型的过拟合曲线。Epoch 2 为验证集上的"甜蜜点", 此后模型开始记忆训练数据噪声。

2.4.3 解决的关键 Bug

(1) 损失曲线绘制报错 ValueError: x and y must have same first dimension

原因: 训练 loss 和验证 loss 的 x 轴数据长度不一致。

解决: 分别存储 train_steps (基于 epoch 小数步) 和 eval_epochs (整数轮数), 分开绘图。

(2) 推理时加载 checkpoint 路径错误 Repo id must be in the form...

原因: 手动指定的 checkpoint 数字不存在。

解决: 实现 find_best_checkpoint() 函数, 自动扫描 ./results/ 下数字最大的文件夹。

(3) 本地 BERT 加载时出现大量 UNEXPECTED/MISSING keys 警告

原因: 本地 bert-base-uncased 权重使用旧版 LayerNorm 命名 (gamma/beta), 而 transformers 库新版期望 (weight/bias), 系命名差异而非权重缺失。

解决: 忽略警告, 不影响微调。此现象系本地权重版本与库版本不一致所致, 不影响模型性能。

(4) 训练效率

全量 25,000 条训练 3 epoch, 总耗时约 20 分钟 (1197 秒), 训练速度 62.65 samples/s, 评估速度 328.7 samples/s (Epoch 1-2)。

2.5 总结与改进建议

2.5.1 实验总结

成功使用 BERT 在全量 IMDB 数据集上微调, 达到 Accuracy 89.08%, 接近作业 90% 的目标。发现模型对转折句 (but/although)、评分矛盾和短文本泛化能力不足, 错误样本分析揭示了 BERT 的局限性。

训练过程中验证 loss 在 Epoch 2 后反弹, 提示需要早停。Epoch 2 的验证 F1 (0.8948) 高于最终报告值, 进一步印证此结论。

训练效率较高：全量数据 3 epoch 仅需约 20 分钟，BERT 微调在消费级 GPU（RTX 4060 8GB）上可行。

2.5.2 改进建议

早停与正则化：在验证 loss 不再下降时停止（Epoch 2），或增加 weight_decay 到 0.1。

数据增强：对含转折词的样本进行过采样，或通过回译生成变体。

模型升级：尝试 RoBERTa 或 DeBERTa（通常比 BERT 高 1-2 个百分点）。

规则后处理：对极短文本或特定否定模式加入简单规则，提高鲁棒性。

更长上下文：若硬件允许，将 max_length 提升到 512，捕捉更多信息。

附录：AI 使用声明

本报告在撰写过程中使用了 DeepSeek 辅助：

整理文献综述的思路和关键点。

调试代码中的 Bug（损失曲线绘制、checkpoint 路径查找、LayerNorm 命名警告分析）。

润色报告文字，使其更符合学术规范。

所有核心技术内容（实验设计、超参数选择、错误分析、调参决策）均由作者独立完成，AI 仅提供信息检索和语言支持。

参考文献

- [1] Pang, B., Lee, L., & Vaithyanathan, S. (2002). Thumbs up? Sentiment Classification using Machine Learning Techniques. Proceedings of EMNLP, 79–86.
- [2] Mikolov, T., Chen, K., Corrado, G., & Dean, J. (2013). Efficient Estimation of Word Representations in Vector Space. arXiv preprint arXiv:1301.3781.
- [3] Kim, Y. (2014). Convolutional Neural Networks for Sentence Classification. Proceedings of EMNLP, 1746–1751.
- [4] Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. Neural Computation, 9(8), 1735–1780.
- [5] Vaswani, A., Shazeer, N., Parmar, N., et al. (2017). Attention Is All You Need. Advances in Neural Information Processing Systems (NeurIPS).

- [6] Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. Proceedings of NAACL-HLT, 4171–4186.
- [7] Brown, T. B., Mann, B., Ryder, N., et al. (2020). Language Models are Few-Shot Learners. Advances in Neural Information Processing Systems (NeurIPS).